

Групповой проект №1.

2026_AITH: Speech recognition and generation

Попов Игорь Владленович

Задача - распознавание чисел в диапазоне [1000, 999999] по аудио на русском языке. Используется Conformer из torchvision (~4.05М параметров) с обучением в PyTorch Lightning. Используется CTC Loss с фиксированным словарём из 42 токенов (41 слово + blank). Словарь выбран на уровне слов (например, «один», «двадцать» и тд), а не символов, поскольку пространство возможных комбинаций ограничено и хорошо структурировано: все числа строятся из небольшого набора повторяющихся слов. Это упрощает декодирование, ускоряет сходимость и снижает вероятность ошибок по сравнению с посимвольным подходом, где модель должна дополнительно учить орфографию и корректную сборку слов из букв.

Для повышения устойчивости к out-of-domain спикерам применяются аугментации из audiomomentations (шумы, искажения, временные/частотные преобразования, симуляция помещения). Эксперимент с KenLM 4-gram для рескоринга beam search не дал улучшений, так как при словарной токенизации языковая модель практически не добавляет новой информации.

Метрики на валидации:

Speaker	Samples	Accuracy	CER	
spk_A	100	99.0%	0.0017	[inD]
spk_B	100	100.0%	0.0000	[inD]
spk_C	100	99.0%	0.0017	[inD]
spk_D	100	94.0%	0.0118	[inD]
spk_E	100	100.0%	0.0000	[inD]
spk_F	100	98.0%	0.0051	[inD]
spk_H	633	97.8%	0.0053	[ooD]
spk_I	497	81.5%	0.0577	[ooD]
spk_J	344	95.1%	0.0084	[ooD]
spk_K	191	87.4%	0.0223	[ooD]
Overall	2265	93.1%	0.0182	
inD CER	600		0.0034	
ooD CER	1665		0.0235	
HM-CER			0.0059	← primary metric

Late Submission на Kaggle

Место: 8 на Public, 4 на Private (примерно, так как Kaggle не отображает late submission на лидерборде)



submission.csv

Complete (after deadline) · 8d ago

1.167

1.152