Домашняя работа №2.
2026_AITH: Speech recognition and generation

Попов Игорь Владленович

Part 1 — CTC Decoding

Task 1. Имплементация Greedy декодирования

method	WER	CER
greedy	11.22%	3.81%

Полученные результаты примерно похожи на референсные значения.

Task 2. Имплементация Beam Search декодирования

method	beam_width	wer	cer	dt
beam	1	11.24%	3.80%	00:00:23
beam	3	11.15%	3.78%	00:00:29
beam	10	11.07%	3.77%	00:00:47
beam	25	11.12%	3.78%	00:01:54
beam	50	11.10%	3.77%	00:03:50

С ростом параметра **beam_width** существенно увеличивается время декодирования, а снижение ошибок **WER** и **CER** скорее незначительное. Оптимальным значением параметра **beam_width** с точки зрения компромисса точности vs скорости является значение **beam_width=10.** Однако для декодирования с языковой моделью (LM) далее используется **beam_width=25**, так как при малых значениях **beam_width** влияние языковой модели выражено слабее из-за ограниченного числа рассматриваемых гипотез.

Task 3. Анализ влияния температуры для Greedy декодирования

method	temperature	WER	CER
greedy	0.5	11.22%	3.81%
greedy	0.8	11.22%	3.81%
greedy	1.0	11.22%	3.81%
greedy	1.2	11.22%	3.81%
greedy	1.5	11.22%	3.81%
greedy	2.0	11.22%	3.81%

При изменении параметра температуры метрики ожидаемо не меняются, так как в **greedy** алгоритме мы используем argmax по логитам, результат функции которого не зависит от калибровки логитов с помощью температуры.

Part 2 — Language Model Integration

Task 4. Анализ параметров alpha и beta для Shallow Fusion

method	alpha	beta	WER	CER
beam_lm	0.01	0.0	11.12%	3.78%
beam_lm	0.01	0.5	11.05%	3.76%
beam_lm	0.01	1.0	11.27%	3.80%
beam_lm	0.01	1.5	11.32%	3.80%
beam_lm	0.05	0.0	11.12%	3.78%
beam_lm	0.05	0.5	11.05%	3.76%
beam_lm	0.05	1.0	11.27%	3.79%
beam_lm	0.05	1.5	11.32%	3.80%
beam_lm	0.1	0.0	11.10%	3.78%
beam_lm	0.1	0.5	11.05%	3.76%
beam_lm	0.1	1.0	11.10%	3.76%
beam_lm	0.1	1.5	11.32%	3.80%
beam_lm	0.5	0.0	11.44%	3.82%
beam_lm	0.5	0.5	11.12%	3.78%
beam_lm	0.5	1.0	11.05%	3.76%
beam_lm	0.5	1.5	11.02%	3.75%
beam_lm	1.0	0.0	11.76%	3.91%
beam_lm	1.0	0.5	11.71%	3.89%
beam_lm	1.0	1.0	11.32%	3.82%
beam_lm	1.0	1.5	11.12%	3.79%
beam_lm	2.0	0.0	19.90%	5.50%
beam_lm	2.0	0.5	16.99%	4.96%
beam_lm	2.0	1.0	15.55%	4.70%
beam_lm	2.0	1.5	13.71%	4.28%
beam_lm	5.0	0.0	99.98%	22.50%
beam_lm	5.0	0.5	99.98%	22.50%
beam_lm	5.0	1.0	99.98%	22.50%
beam_lm	5.0	1.5	99.98%	22.50%

Оптимальным набором параметров для декодирования с использованием языковой модели (LM) в результате экспериментов является пара **alpha=0.5**, **beta=1.5.** Можно заметить, что при больших параметре alpha ошибка стремительно растет вплоть до 99% WER.

Task 5. Сравнение 3-gram LM и 4-gram LM

При одинаковых параметрах **alpha=0.5**, **beta=1.5, beam_width=25.** У модели 4-gram даже наблюдается посадка по метрикам. В принципе это нормально, использование 4-gram модели не гарантирует лучших результатов. При этом стоит отметить, что указанные параметры выбирались оптимальными именно для 3-gram модели. Для более честного результата стоит и под 4-gram модель подбирать оптимальный сетап.

method	alpha	beta	WER	CER	LM
beam_lm	0.5	1.5	11.02%	3.75%	3-gram
beam_lm	0.5	1.5	11.27%	3.80%	4-gram

Task 6. Анализ параметров alpha и beta для LM Rescoring

method	alpha	beta	WER	CER	dt
beam_lm_rescore	0.01	0.0	11.12%	3.78%	00:01:46
beam_lm_rescore	0.01	0.5	11.02%	3.75%	00:01:46
beam_lm_rescore	0.01	1.0	11.07%	3.76%	00:01:47
beam_lm_rescore	0.01	1.5	11.17%	3.77%	00:02:52
beam_lm_rescore	0.05	0.0	11.12%	3.78%	00:01:48
beam_lm_rescore	0.05	0.5	11.05%	3.76%	00:01:48
beam_lm_rescore	0.05	1.0	11.07%	3.76%	00:01:48
beam_lm_rescore	0.05	1.5	11.17%	3.77%	00:01:48
beam_lm_rescore	0.1	0.0	11.12%	3.78%	00:01:48
beam_lm_rescore	0.1	0.5	11.05%	3.76%	00:01:49
beam_lm_rescore	0.1	1.0	11.07%	3.76%	00:01:48
beam_lm_rescore	0.1	1.5	11.15%	3.76%	00:01:48
beam_lm_rescore	0.5	0.0	11.29%	3.81%	00:01:49
beam_lm_rescore	0.5	0.5	11.15%	3.78%	00:01:49
beam_lm_rescore	0.5	1.0	11.05%	3.76%	00:01:48
beam_lm_rescore	0.5	1.5	11.12%	3.76%	00:01:49
beam_lm_rescore	1.0	0.0	11.54%	3.84%	00:01:49
beam_lm_rescore	1.0	0.5	11.39%	3.82%	00:01:48
beam_lm_rescore	1.0	1.0	11.20%	3.79%	00:01:48
beam_lm_rescore	1.0	1.5	11.07%	3.77%	00:01:49
beam_lm_rescore	2.0	0.0	12.27%	3.93%	00:01:50
beam_lm_rescore	2.0	0.5	11.95%	3.90%	00:01:48
beam_lm_rescore	2.0	1.0	11.76%	3.87%	00:01:47
beam_lm_rescore	2.0	1.5	11.59%	3.85%	00:01:45
beam_lm_rescore	5.0	0.0	13.93%	4.14%	00:01:44
beam_lm_rescore	5.0	0.5	13.93%	4.14%	00:01:44
beam_lm_rescore	5.0	1.0	13.88%	4.13%	00:01:44
beam_lm_rescore	5.0	1.5	13.76%	4.11%	00:01:49

Оптимальным набором параметров для декодирования с использованием языковой модели (LM) с рескорингом в результате экспериментов является пара **alpha=0.01**, **beta=0.5.** При этом достаточно много комбинаций этих параметров показывают практически такие же метрики. Для следующих экспериментов будет выбрана пара **alpha=0.5**, **beta=1.0**, которая слегка проигрывает наилучшей, но потенциально позволяет лучше отслеживать влияние языковой модели на результат.

Также стоит отметить, что при рескоринге большие значения alpha уже не так сильно ухудшают метрики, по сравнению с Shallow Fusion, что может быть связано с тем, что языковая модель применяется только на финальном этапе и не влияет на ранние стадии поиска гипотез.

6b. Сравнение предсказаний с референсом:
LM в основном исправляет ошибки в пробелах (*might doit -> might do it*). Однако LM не способна исправлять акустические ошибки, а также ошибки в редких или сложных словах, которые изначально предсказываются с большим количеством искажений (*alkward*). При этом в некоторых случаях LM еще может ухудшить результат добавляя лишние пробелы (*another anda -> an other an a*)

```
==================================================
 REF: a fellow who was shut up in prison for life might do it he said but not in a case like this
BEAM: a fellow who as shut up in prison for life might doit he said but not in a case like this
  SF: a fellow who as shut up in prison for life might do it he said but not in a case like this
  RS: a fellow who as shut up in prison for life might do it he said but not in a case like this
==================================================
 REF: and why did andy call mister gurr father
BEAM: and why did andy call mister gurfather
  SF: and why did andy call mister gur father
  RS: and why did andy call mister gur father
==================================================
 REF: why your clothes don't fit you and your cap's put on all skew rew
BEAM: why you'r clothes ont fit you and you'r caps put on alskiru
  SF: why you'r clothes ont fit you and you'r caps put on alskuiru
  RS: why you'r clothes ont fit you and you'r caps put on alskuiru
==================================================
 REF: that's right of course well armed
BEAM: that's right of course willamed
  SF: that's right of course will amed
  RS: that's right of course will amed
==================================================
 REF: awkward bit o country sir six miles row before you can find a place to land
BEAM: alkward but a country sir six miles oro before you cand find a place to land
  SF: alkward but a country sir six miles or o before you cand find a place to land
  RS: alkward but a country sir six miles or o before you cand find a place to land
==================================================
 REF: no wait another half hour
BEAM: no where another anda half hour
  SF: no where an other an a half hour
  RS: no where another an a half hour
==================================================
 REF: pipe away the men to that boat there he said and as the crew sprang in
BEAM: pip away the men to that boat there he said and as the crewsprang in
  SF: pip away the men to that boat there he said and as the crew sprang in
  RS: pip away the men to that boat there he said and as the crew sprang in
==================================================
```

Task 7. Сравнение моделей на датасетах LibriSpeech и Earnings_22

Method	LibriSpeech WER	LibriSpeech CER	Earnings 22 WER	Earnings 22 CER
greedy	11.22%	3.81%	54.97%	25.58%
beam	11.07%	3.77%	54.94%	25.38%
beam_lm	11.02%	3.75%	56.66%	25.49%
beam_lm_rescore	11.05%	3.76%	55.24%	25.44%

Наблюдается значительный разрыв между качеством на LibriSpeech и Earnings_22, что обусловлено доменным различием как в акустике, так и в языке. Языковая модель, обученная на LibriSpeech практически не улучшает результаты на финансовом датасете, поскольку не отражает специфическую лексику и структуру предложений в данном домене. В результате она не может эффективно обрабатывать гипотезы и оказывать заметное влияние на декодирование.

7b. Влияние температуры на Out of Domain распознавание
Для датасета Earnings22 при увеличении температуры при декодировании с Shallow Fusion ошибка растет. Вероятно, повышение температуры негативно влияет, так как сглаживает распределение вероятностей акустической модели и снижает ее уверенность. Влияние языковой модели становится относительно сильнее, но она не может компенсировать ошибки акустической модели на данных из другого домена.

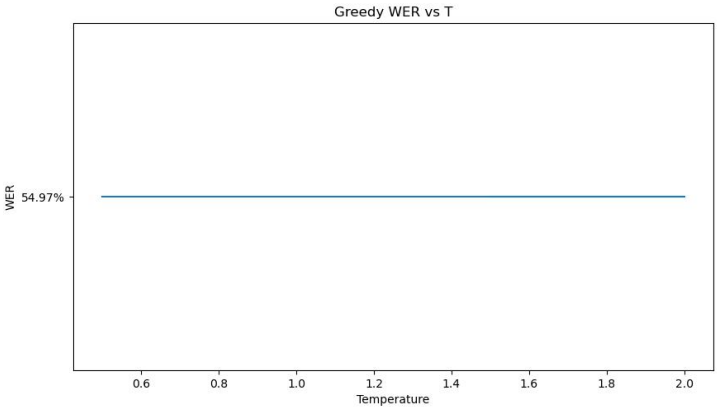

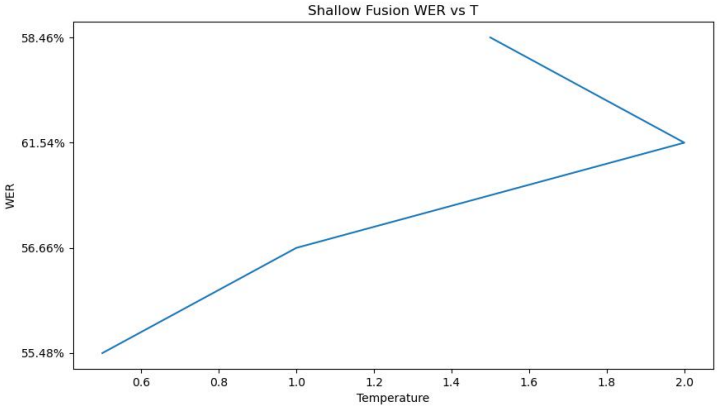

method	temperature	WER	CER
beam_lm	0.5	55.48%	25.50%
beam_lm	1.0	56.66%	25.49%
beam_lm	2.0	61.54%	26.14%
beam_lm	1.5	58.46%	25.69%

Task 9. Обучение кастомной LM модели на Earnings_22

Method	Model	LibriSpeech WER	LibriSpeech CER	Earnings 22 WER	Earnings 22 CER
beam_lm	LibriSpeech 3-gram	11.02%	3.75%	56.66%	25.49%
beam_lm_rescore	LibriSpeech 3-gram	11.05%	3.76%	55.24%	25.44%
beam_lm	Financial 3-gram	12.71%	4.05%	51.57%	25.84%
beam_lm_rescore	Financial 3-gram	11.59%	3.84%	52.71%	25.05%

LibriSpeech 3-gram LM показывает лучшие результаты на LibriSpeech, тогда как Financial 3-gram LM - на Earnings_22. При этом Financial LM ухудшает качество вне своего домена, но заметно улучшает его в целевом домене, что подтверждает важность доменной адаптации.